

Aproximación por Mínimos Cuadrados

Análisis Numérico y Modelado de Datos

Miguel Ángel Chávez García Alejandro Martínez Ireneo

Licenciatura en Actuaría
FES Acatlán – UNAM

24,25 y 26 de junio de 2026

Estructura de la Exposición

- 1 Teoría
- 2 Estadística
- 3 Generalización
- 4 Modelos
- 5 Final

Planteamiento del problema

Suponga que se tiene una colección de datos de la siguiente forma $A = \{(x_i, y_i) \in \mathbb{R}^2 : i \in \{1, \dots, n\}\}$. Así que una pregunta es

¿Existe una función que pase por todos los puntos del conjunto A ?

Esto depende si al menos dos puntos tienen la misma abscisa, en caso que no se tenga lo anterior se puede pensar en la existencia de alguna función, por ejemplo polinomial.

La distribución de los puntos puede ser aleatoria, entonces buscar una función que pase por todos los puntos no siempre existe, sin embargo si se puede pensar en la ecuación de una recta de la forma

$$l := y = ax + b, \quad a, b \in \mathbb{R},$$

tal que haga la distancia de cada ordenada y_i a la recta l sea mínima.

Deducción de los mínimos cuadrados(1)

Geométricamente es encontrar la recta l que haga mínima la distancia de las ordenadas entre los elementos de A y l . Entonces para resolver el presente problema usemos el cálculo multivaribale, definamos la función:

$$E(a, b) = \sum_{i=1}^n [y_i - (ax_i + b)]^2.$$

Buscamos minimizar esta función de dos variables la cual es diferenciable.

Condición de Optimalidad

Tal como se establece en **Chávez García (2014)**, requerimos:

$$\nabla E(a, b) = \mathbf{0} \implies \left(\frac{\partial E}{\partial a}, \frac{\partial E}{\partial b} \right) = (0, 0).$$

Deducción de los mínimos cuadrados (2)

Es decir se genera el sistema para cada $i, i \in \{1, \dots, n\}$

$$\begin{cases} 2(y_i - (ax_i + b))(-x_i) &= 0 \\ 2(y_i - (ax_i + b)) &= 0. \end{cases}$$

Entonces

$$\begin{cases} ax_i^2 + bx_i &= x_i y_i \\ ax_i + b &= y_i. \end{cases}$$

Al sumar desde 1 a n .

$$\begin{cases} a \sum_{i=1}^n x_i^2 + b \sum_{i=1}^n x_i &= \sum_{i=1}^n x_i y_i \\ a \sum_{i=1}^n x_i + \sum_{i=1}^n b &= \sum_{i=1}^n y_i. \end{cases}$$

Genera el sistema de ecuaciones lineales

Deducción de los mínimos cuadrados (3)

$$\begin{pmatrix} \sum_{i=1}^n x_i^2 & \sum_{i=1}^n x_i \\ \sum_{i=1}^n x_i & n \end{pmatrix} \begin{pmatrix} a \\ b \end{pmatrix} = \begin{pmatrix} \sum_{i=1}^n x_i y_i \\ \sum_{i=1}^n y_i \end{pmatrix}$$

Usando Cramer, se sigue

$$a = \frac{(n \sum_{i=1}^n x_i y_i) - (\sum_{i=1}^n y_i \sum_{i=1}^n x_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}$$

$$b = \frac{(\sum_{i=1}^n x_i^2 \sum_{i=1}^n y_i) - (\sum_{i=1}^n x_i \sum_{i=1}^n x_i y_i)}{n \sum_{i=1}^n x_i^2 - (\sum_{i=1}^n x_i)^2}.$$

La cual es la solución el sistema y restaría probar que en efecto (a, b) con esos valores alcanza su mínimo. Lo cual se deduce a partir de que la función $E(a, b)$ es una forma cuadrática definida positiva y por ende tiene un mínimo global.

Interpretación Estadística (1)

De la ecuación $a \sum_{i=1}^n x_i + nb = \sum_{i=1}^n y_i$ se tiene que

$$b = \frac{1}{n} \sum_{i=1}^n y_i - a \left(\frac{1}{n} \sum_{i=1}^n x_i \right).$$

Así

$$b = \bar{y} - a\bar{x}, \quad \bar{y} = \frac{1}{n} \sum_{i=1}^n y_i, \quad \bar{x} = \frac{1}{n} \sum_{i=1}^n x_i.$$

Los cuales son los promedios de las ordenadas y abscisas respectivamente.
Para a se tiene

$$a = \frac{\frac{1}{n^2} \left[\left(n \sum_{i=1}^n x_i y_i \right) - \left(\sum_{i=1}^n y_i \sum_{i=1}^n x_i \right) \right]}{\frac{1}{n^2} \left[n \sum_{i=1}^n x_i^2 - \left(\sum_{i=1}^n x_i \right)^2 \right]} =$$

$$a = \frac{\left(\frac{1}{n} \sum_{i=1}^n x_i y_i \right) - \left(\frac{1}{n} \sum_{i=1}^n y_i \frac{1}{n} \sum_{i=1}^n x_i \right)}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \left(\frac{1}{n} \sum_{i=1}^n x_i \right)^2} = \frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \cdot \bar{y}}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2}$$

Interpretación Estadística (2)

Al desarrollar se observa la siguiente identidad

$$\frac{\frac{1}{n} \sum_{i=1}^n x_i y_i - \bar{x} \cdot \bar{y}}{\frac{1}{n} \sum_{i=1}^n x_i^2 - \bar{x}^2} = \frac{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2}.$$

Los cuales en estadística se define como

Varianza y Covarianza

$$\text{Cov}(X, Y) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y}), \text{Var}(X) = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2.$$


Así

$$a = \frac{\text{Cov}(X, Y)}{\text{Var}(X)} = \frac{\sum (x_i - \bar{x})(y_i - \bar{y})}{\sum (x_i - \bar{x})^2}.$$

Al resolver el sistema de ecuaciones normales, la pendiente a se puede expresar en términos de momentos estadísticos:

Esto vincula el ajuste numérico directamente con la correlación de los datos.

Mínimos cuadrados su geometría



La recta azul representa la solución el problema de mínimos cuadrados.

Polinomios de grado 2 a m (1)

Ahora surge una pregunta natural: ¿Solo se puede hacer dicho método con respecto a una recta? Y la respuesta es que no. Es decir se pueden meter polinomios de grado mayores o iguales que dos pero que sean finitos. Es decir funciones de la forma

$$P_m(x) = \sum_{i=0}^m a_i x^i$$

donde $a_i \in \mathbb{R}$, $i \in \{0, 1, \dots, m\}$.

Para un modelo polinomial, se obtiene una función de $m + 1$ variables para los n datos que se tienen:

$$E(a_m, \dots, a_1, a_0) = \sum_{i=1}^n (y_i - P_m(x_i))^2.$$

Polinomios de grado 2 a m (2)

La función es convexa y diferenciable, así que podemos usar el cálculo multivariable para encontrar su mínimo y solo basta resolver la siguiente ecuación

Condición para optimización

$$\nabla E(a_m, \dots, a_1, a_0) = (0, \dots, 0), (0, \dots, 0) \in \mathbb{R}^{m+1}.$$

Así se obtiene el siguiente sistema de ecuaciones iniales

$$\begin{aligned} \sum_{i=1}^n (y_i - P_m(x_i))(-x_m) &= 0 \\ \sum_{i=1}^n (y_i - P_m(x_i))(-x_{m-1}) &= 0 \\ &\vdots \\ \sum_{i=1}^n (y_i - P_m(x_i))(-1) &= 0 \end{aligned}$$

De donde se obtienen matrices

$$H \in M_{(m+1) \times (m+1)}(\mathbb{R}), A \in M_{(m+1) \times 1}(\mathbb{R}), C \in M_{(m+1) \times 1}(\mathbb{R})$$

Polinomios de grado 2 a m (3)

Entonces el sistema de ecuaciones se puede escribir en forma de matrices

$$H \cdot A = C,$$

es decir

$$\begin{pmatrix} h_{11} & \dots & h_{1m+1} \\ \vdots & & \vdots \\ h_{m+11} & \dots & h_{m+1m+1} \end{pmatrix} \begin{pmatrix} a_m \\ \vdots \\ a_0 \end{pmatrix} = \begin{pmatrix} c_m \\ \vdots \\ c_0 \end{pmatrix}$$

Nos interesa saber si el presente sistema tiene solución y si esta es única. Para no calcular las derivadas de la función $E(a_m, \dots, a_1, a_0)$ vamos a dar argumentos para analizar H y garantizar la existencia de soluciones. Lo cual nos da la pauta para realizar las operaciones y con ello deducir e implementar el algoritmo de solución.

Existencia de soluciones a polinomios de grado m

Teorema (Existencia y unicidad de la solución)

El sistema de ecuaciones normales $H \cdot A = C$ siempre posee una solución única y global por las siguientes condiciones estructurales:

- ❶ **Convexidad estricta:** *La función $E : \mathbb{R}^{m+1} \rightarrow \mathbb{R}$ es una forma cuadrática estrictamente convexa, lo que garantiza geoméricamente que la superficie es un paraboloide generalizado que abre hacia arriba, asegurando la existencia de un mínimo global.*
- ❷ **Índice de Morse igual a cero:** *Por Teoría de Morse, al tratarse de un mínimo global no degenerado, el índice de Morse del punto crítico es exactamente cero. Esto implica analíticamente que la matriz Hessiana (proporcional a la matriz de momentos H) es definida positiva y sus valores propios son todos positivos.*
- ❸ **Matriz invertible:** *Al ser H una matriz simétrica y definida positiva, $\det(H) > 0$. La matriz H es invertible, asegurando que el sistema lineal tiene una única solución $A \in \mathbb{R}^{m+1}$.*

¿Qué sucede con las demás funciones?

Siguiendo esta idea podemos hacer el mismo análisis para funciones que no necesariamente sean polinomios, lo que se pide es que la función sea diferenciable en un dominio dado y eso abre el espacio de las funciones donde podemos trabajar.

Por ejemplo se pueden poner las funciones $f(x) = e^x$, $g(x) = \ln x$ y emplear la misma metodología. Pero aquí se tiene un problema ya que el sistema de soluciones no necesariamente se pueden obtener analíticamente como es el caso de la exponencial y pues ahí de nuevo se emplean algoritmos numéricos para dar soluciones.

Se usan las siguientes funciones con ese enfoque

- **Exponencial:** $y = be^{ax} \rightarrow \ln y = \ln b + ax$.
- **Logarítmico:** $y = a \ln x + b$.

Conclusiones: ¿Con qué modelamos?

¿Cuál es el mejor modelo?

Ante la pregunta de cuál modelo elegir para describir la realidad de los datos, la respuesta analítica nos la heredó el estadístico George E. P. Box:

“Todos los modelos son falsos, pero algunos son útiles.”

— George E. P. Box

En el contexto de nuestro curso de Análisis Numérico:

- **No existe un modelo matemáticamente absoluto.** Un polinomio de grado superior puede pasar por todos los puntos pero colapsar ante datos nuevos debido al mal condicionamiento de la matriz de momentos.
- **El criterio es la utilidad y el costo métrico.** Linealizar con un logaritmo nos da simplicidad analítica, pero deforma la realidad del error. Mantener el modelo exponencial salvaje nos obliga al uso de métodos numéricos, pero respeta la métrica original.

Bibliografía



R. Burden & J. Faires. *Análisis Numérico*. 2015.



J. R. Giles. *Analysis of Metric Spaces*. 1987.



M. A. Chávez García. *Cálculo Diferencial e Integral III*. 2014.